

Tech Challenge

Fase 02

FIAP

Análise Preditiva da
Tendência do IBOVESPA

Desafio

O problema de negócio

Desenvolver modelos de Machine Learning capazes de prever a tendência direcional (alta ou baixa) do IBOVESPA no dia seguinte, utilizando dados históricos de mercado.

A previsão de mercado é notoriamente desafiadora devido à natureza ruidosa e não-linear das séries temporais financeiras.



Pipeline de construção do modelo

➤ Aquisição	Download automatizado de dados diários via biblioteca yfinance, garantindo dados atualizados.
➤ Variável alvo	Criação da tendência (trend) baseada no fechamento do dia seguinte para classificação binária.
➤ Engenharia de features	Foco em indicadores técnicos como retornos (1, 3, 5 dias) e volatilidade (5, 10 dias).
➤ Tratamento	Remoção de inconsistências e limpeza de valores nulos resultantes dos cálculos estatísticos.

Engenharia de Features

↗ Retornos percentuais

ret_1, ret_3, ret_5: retornos percentuais de 1, 3 e 5 dias

↗ Volume financeiro

Volume de negociação diário como indicador de liquidez

↗ Volatilidade histórica

vol_5, vol_10: desvio padrão dos retornos em janelas de 5 e 10 dias

↗ Escalonamento

Uso de StandardScaler para normalizar as features.

Engenharia de Features

```
1 df["ret_1"] = df["Close"].pct_change()  
2 df["ret_3"] = df["Close"].pct_change(3)  
3 df["ret_5"] = df["Close"].pct_change(5)  
4  
5 df["vol_5"] = df["ret_1"].rolling(5).std()  
6 df["vol_10"] = df["ret_1"].rolling(10).std()
```

```
scaler = StandardScaler()  
  
X_train_scaled = scaler.fit_transform(X_train)  
X_test_scaled = scaler.transform(X_test)
```

```
features = ["ret_1", "ret_3", "ret_5", "vol_5", "vol_10", "Volume"]
```


Modelos testados



Regressão Logística: Baseline para avaliar a linearidade e o poder preditivo real das features construídas.



K-Nearest Neighbors (KNN): Investiga se o mercado repete comportamentos sob condições técnicas semelhantes.



Random Forest: Benchmark de estabilidade e equilíbrio entre desempenho e tratamento de não-linearidades.



Support Vector Machine (SVM): Focado em maximizar a margem de separação, lidando bem com dados ruidosos e margens pequenas.



XGBoost: Algoritmo de boosting robusto para capturar interações complexas e sinais fracos no mercado.

```
models = {  
    "KNN": KNeighborsClassifier(  
        n_neighbors=13,  
        weights="distance"  
    ),  
  
    "Random Forest": RandomForestClassifier(  
        n_estimators=300,  
        max_depth=5,  
        random_state=42  
    ),  
  
    "Logistic Regression": LogisticRegression(  
        max_iter=1000,  
        solver="lbfgs"  
    ),  
  
    "SVM": SVC(  
        kernel="rbf",  
        C=1.0,  
        gamma="scale"  
    ),  
  
    "XGBoost": XGBClassifier(  
        n_estimators=300,  
        max_depth=3,  
        learning_rate=0.05,  
        subsample=0.8,  
        colsample_bytree=0.8,  
        eval_metric="logloss",  
        random_state=42  
    )  
}
```

Resultados iniciais

Performance dos modelos no conjunto de teste de 30 dias (2 anos de treinamento)

MODELO	ACURÁCIA	F1 QUEDA (0)	F1 ALTA (1)
Logistic Regression	0.667	0.500	0.750
KNN	0.633	0.421	0.732
SVM	0.567	0.316	0.683
Random Forest	0.467	0.385	0.529
XGBoost	0.367	0.174	0.486

→ **Regressão Logística** apresentou a melhor acurácia (66.7%) e o melhor F1-Score para previsão de alta.

Análise de sensibilidade

↗ Variação temporal

Testamos janelas de treinamento de **1 a 10 anos** para identificar o período ótimo de dados históricos.

↗ Threshold agressivo

Threshold de **0.40** testado para modelos mais propensos a prever alta.

Testes

Melhores Resultados (por métrica)

↗ Acurácia

70%

KNN com 2 anos de
treinamento (threshold 0.40)

↗ AUC

0.705

Logistic Regression com 10
anos de treinamento

↗ Balanceamento

60%

SVM com 9 anos de
treinamento (AUC 0.630)

Conclusões da Análise

1

Logistic Regression (10 anos)

Melhor para análise de sentimento geral do mercado.
Maior AUC (0.705) indica contexto favorável à alta.

```
1 df_temporal.sort_values(by="AUC", ascending=False).head(10)
```

	Modelo	Anos_Treinamento	Acurácia	AUC	F1 Classe 0	F1 Classe 1
47	Logistic Regression	10	0.666667	0.705	0.000000	0.800000

2

KNN (2 anos)

Maior acurácia bruta (70%).
Comportamento recente do mercado é mais relevante para curto prazo.

```
1 df_temporal.sort_values(by="Acurácia", ascending=False).head(10)
```

	Modelo	Anos_Treinamento	Acurácia	AUC	F1 Classe 0	F1 Classe 1
5	KNN	2	0.700000	0.560	0.400	0.800000

3

SVM (9 anos)

Melhor balanceamento entre classes. Maior capacidade de generalização e menos viés.

	Modelo	Anos_Treinamento	Acurácia	AUC	F1 Classe 0	F1 Classe 1
47	Logistic Regression	10	0.666667	0.705	0.000000	0.800000
42	Logistic Regression	9	0.666667	0.685	0.000000	0.800000
48	SVM	10	0.566667	0.650	0.480000	0.628571
43	SVM	9	0.600000	0.630	0.571429	0.625000

Recomendação

Estratégia de Modelos Complementares

↗ Modelo 01: Contexto

Logistic Regression (10 anos) para avaliar sentimento geral do mercado

↗ Modelo 02: Direção diária

SVM (9 anos) para definir direção diária de forma balanceada e generalista

A janela de treinamento ideal varia entre modelos, e a otimização do threshold é crítica para ajustar ao perfil de risco desejado.